Lab – News Categorization

File

최성철 교수
Director of TEAMLAB

비슷한 뉴스를
어떻게 선정할까?

가상화폐 광풍

거래소 폐쇄 방침 '혼선'에 비트코인 가격 '롤러코스터'

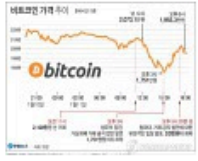

연합뉴스 · 203

비트코인 '거래소 폐지 방침'에 우르르..한… 연합뉴스

정부 가상화폐 때리기에 靑 몰려간 투자자… 연합뉴스

"비트코인은 인생의 동아줄" 2030은 왜?

조선일보 · 441

4차 산업혁명..국민 관심사는 암호화폐? 지디넷코리아

비트코인 광맥 끊기나..중국 채굴 전면 금지

머니투데이 · 327

오라클 웹로직 서버, 암호화폐 채굴에 쓰였다 지디넷코리아

"경찰에 국세청까지" 규제공포에 암호화폐 … 뉴스1

페이스북 부사장 "한국투자 확대..중소기업과 협력 강화"

연합뉴스 · 7

외국계IT기업 '국내 법적 대리인' 의무화 매일경제

'망 무임승차' 논란 페이스북 "사용료 문제 … 연합뉴스

http://media.daum.net/digital/

컴퓨터는 문자를
그대로 이해하지 못함

문자 ➔ 숫자

숫자로 유사하다는 어떻게 표현할까?

유사하다=가깝다

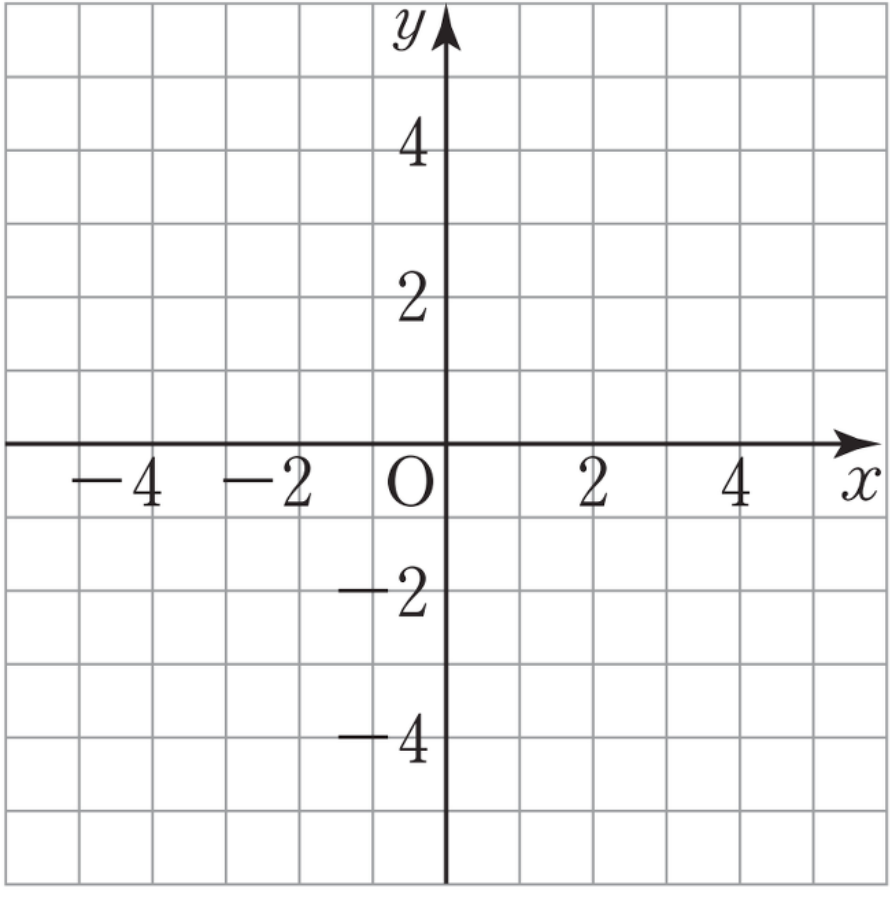
y
4
2
−4
−2
O
2
4
x
−2
−4

문자 ➔ 숫자 ➔ Vector

문자를 Vector로 – One-hot Encoding

- 하나의 단어를 Vector의 Index로 인식, 단어 존재시 1 없으면 0

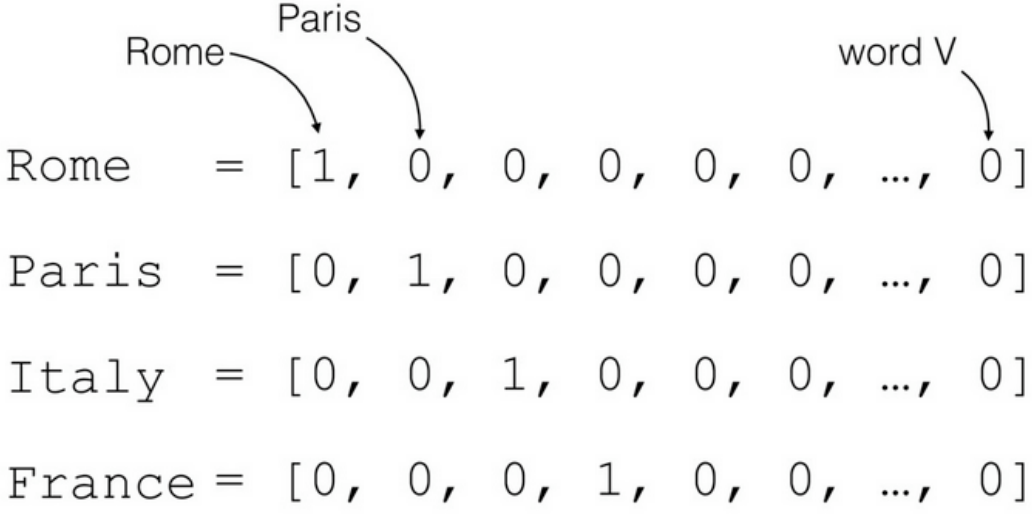

Bag of words

- 단어별로 인덱스를 부여해서, 한 문장(또는 문서)의 단어의 개수를 Vector로 표현

그렇다면 유사성은?

Distance measure

- 고등학교때 배운 2차원 평면상 거리측정 방법들

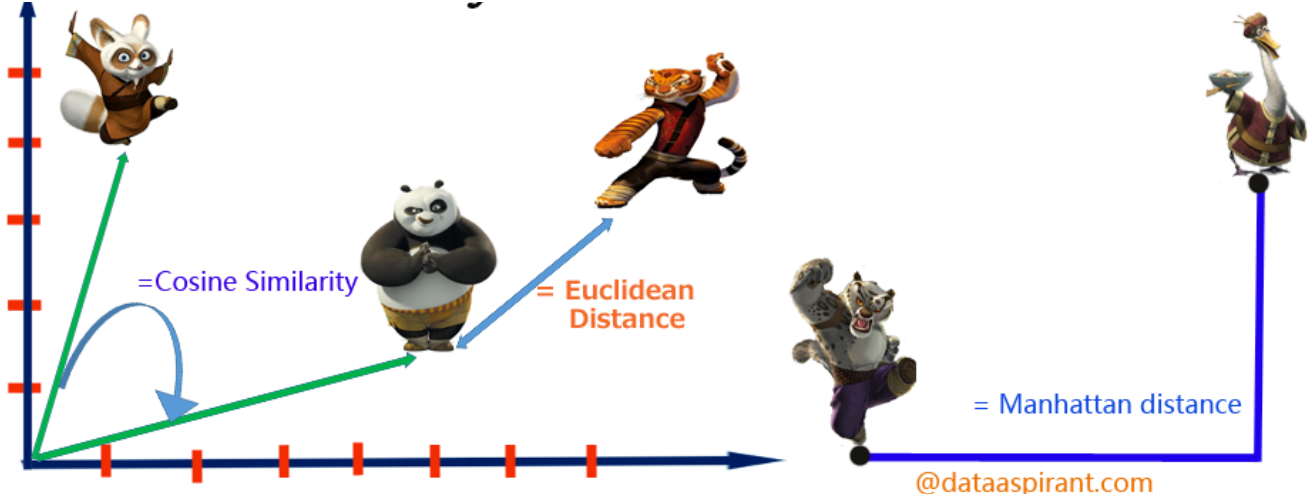

Euclidian distance

- 피타고라스 정리, 두 점 사이의 직선의 거리

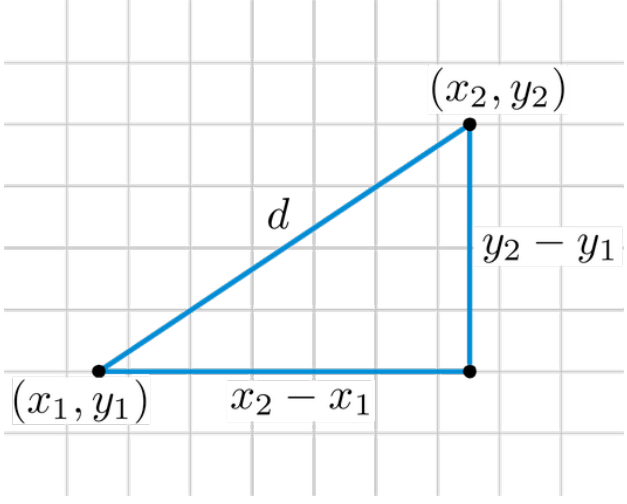

https://goo.gl/cVmeKr

$$\begin{bmatrix} a_1 & a_2 & a_3 & \dots & a_n \end{bmatrix}$$
$$\begin{bmatrix} b_1 & b_2 & b_3 & \dots & b_n \end{bmatrix}$$

$$d(a,b) = \sqrt{\sum_{i}^{n}(a_i - b_i)^2}$$

Cosine distance

- 두 점 사이의 각도

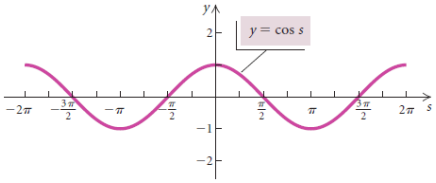

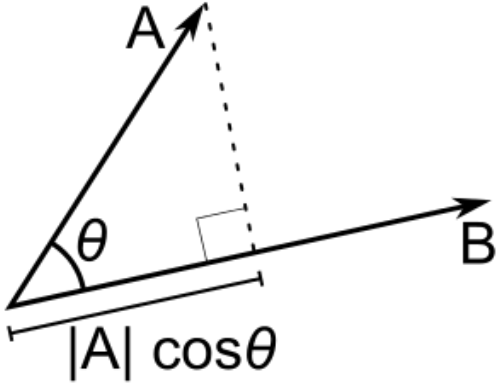

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \, \|B\|} = \frac{\sum_{i=0}^{n} A_i \times B_i}{\sqrt{\sum_{i=0}^{n} (A_i)^2} \times \sqrt{\sum_{i=0}^{n} (B_i)^2}}$$

$$\because A \cdot B = AB\cos(\theta)$$

https://goo.gl/cVmeKr

Cosine distance

- Why cosine similarity? Count < Direction
- Love,hate (5,0), (5,4), (4,0) , 어느점이 가장 가까운가

Codes

Data set

- 축구와 야구 선수들의 영문 기사를 분류해보자!

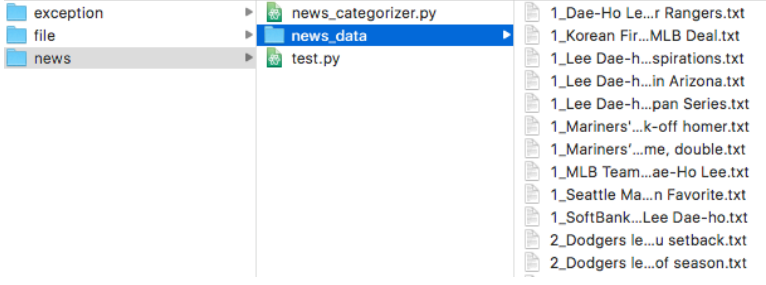

1,2,3,4 야구

5,6,7,8 축구

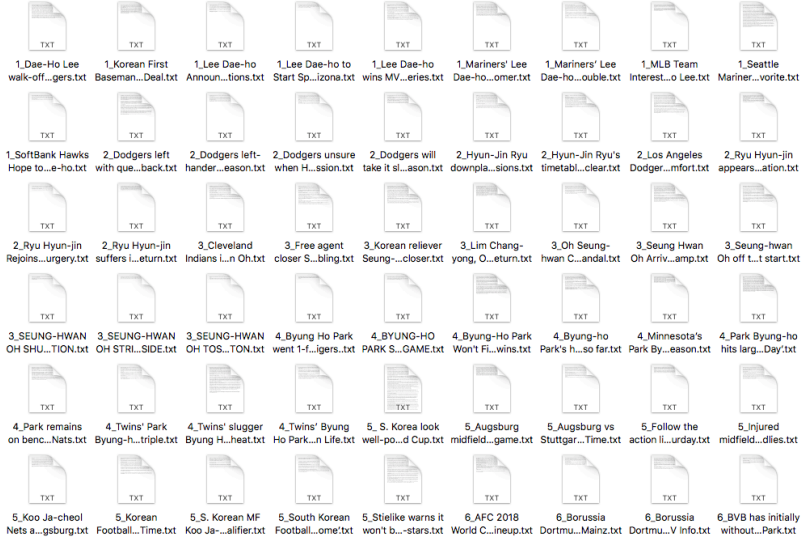

Process

- 파일을 불러오기
- 파일을 읽어서 단어사전 (corpus) 만들기
- 단어별로 Index 만들기
- 만들어진 인덱스로 문서별로 Bag of words vector 생성
- 비교하고자 하는 문서 비교하기
- 얼마나 맞는지 측정하기

파일 불러오기

```
def get_file_list(dir_name):
    return os.listdir(dir_name)


if __name__ == "__main__":
    dir_name = "news_data"
    file_list = get_file_list(dir_name)
    file_list = [os.path.join(dir_name, file_name) for file_name in file_list]
```

파일별로 내용읽기

```
def get_conetents(file_list):
    y_class = []
    X_text = []
    class_dict = {
        1: "0", 2: "0", 3:"0", 4:"0", 5:"1", 6:"1", 7:"1", 8:"1"}


    for file_name in file_list:
        try:
            f = open(file_name, "r",  encoding="cp949")
            category = int(file_name.split(os.sep)[1].split("_")[0])
            y_class.append(class_dict[category])
            X_text.append(f.read())
            f.close()
        except UnicodeDecodeError as e:
            print(e)
            print(file_name)
    return X_text, y_class
```

Corpus 만들기 + 단어별 index 생성하기

의미없는 문장보호 등은 제거하기

```
def get_cleaned_text(text):
    import re
    text = re.sub('\W+','', text.lower() )
    return text


def get_corpus_dict(text):
    text = [sentence.split() for sentence in text]
    clenad_words = [get_cleaned_text(word) for words in text for word in words]


    from collections import OrderedDict
    corpus_dict = OrderedDict()
    for i, v in enumerate(set(clenad_words)):
        corpus_dict[v] = i
    return corpus_dict
```

문서별로 Bag of words vector 생성

```
def get_count_vector(text, corpus):
    text = [sentence.split() for sentence in text]
    word_number_list = [[corpus[get_cleaned_text(word)] for word in words]
for words in text]
    X_vector = [[0 for _ in range(len(corpus))] for x in range(len(text))]


    for i, text in enumerate(word_number_list):
        for word_number in text:
            X_vector[i][word_number] += 1
    return X_vector
```

비교하기

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \, \|B\|} = \frac{\sum_{i=0}^{n} A_i \times B_i}{\sqrt{\sum_{i=0}^{n} (A_i)^2} \times \sqrt{\sum_{i=0}^{n} (B_i)^2}}$$

```
import math
def get_cosine_similarity(v1,v2):
    "compute cosine similarity of v1 to v2: (v1 dot
v2)/{||v1||*||v2||)"
    sumxx, sumxy, sumyy = 0, 0, 0
    for i in range(len(v1)):
        x = v1[i]; y = v2[i]
        sumxx += x*x
        sumyy += y*y
        sumxy += x*y
    return sumxy/math.sqrt(sumxx*sumyy)
```

비교결과 정리하기

```
def get_similarity_score(X_vector, source):
    source_vector = X_vector[source]
    similarity_list = []
    for target_vector in X_vector:
        similarity_list.append(
            get_cosine_similarity(source_vector, target_vector))
    return similarity_list


def get_top_n_similarity_news(similarity_score, n):
    import operator
    x = {i:v for i, v in enumerate(similarity_score)}
    sorted_x = sorted(x.items(), key=operator.itemgetter(1))


    return list(reversed(sorted_x))[1:n+1]
```

성능 측정하기

```
def get_accuracy(similarity_list, y_class, source_news):
    source_class = y_class[source_news]


    return sum([source_class == y_class[i[0]] for i in similarity_list]) /
len(similarity_list)


 for i in range(80):
      source_number = i


      similarity_score = get_similarity_score(X_vector, source_number)
      similarity_news = get_top_n_similarity_news(similarity_score, 10)
      accuracy_score = get_accuracy(similarity_news, y_class, source_number)
      result.append(accuracy_score)
  print(sum(result) / 80)
```

Human knowledge belongs to the world.